

Laboratorio 5 – Sesgo por variable omitida y multicolinealidad

Table of contents

Para empezar	1
Cargar los datos	2
Propiedades de las variables omitidas (Omitted Variable Bias)	3
1) Regresión de IQ sobre <code>educ</code> (para obtener $\tilde{\delta}_1$)	3
2) Regresión de $\log(wage)$ sobre <code>educ</code> (para obtener $\tilde{\beta}_1$)	4
3) Regresión completa de $\log(wage)$ sobre <code>educ</code> y IQ (para obtener $\hat{\beta}_1$ y $\hat{\beta}_2$)	4
Multicolinealidad	6
1) Cargar el set de datos y estimar <code>math4</code> sobre <code>pctsgle</code>	7
2) Correlación entre <code>lmedinc</code> y <code>free</code>	7
3) Modelo con <code>pctsgle</code> , <code>lmedinc</code> y <code>free</code>	8
4) Cálculo de VIF (Variance Inflation Factors)	9
5) ¿Es la multicolinealidad un problema?	9

El propósito de este laboratorio es **comprender mejor el sesgo por variable omitida y la multicolinealidad**. El laboratorio debe completarse en tu grupo. Para obtener crédito, sube tu script `.R` al lugar correspondiente en Canvas.

Para empezar

Abre un nuevo script de R (llámalo `ICL5_XYZ.R`, donde XYZ son tus iniciales) y agrega el “preámbulo” habitual al inicio:

```
# Instalar paquetes solo si faltan (estilo ECO/EPG)
pkgs <- c("tidyverse", "broom", "wooldridge", "car")
to_install <- pkgs[!pkgs %in% rownames(installed.packages())]
if (length(to_install) > 0) {
  install.packages(to_install, repos = "http://cran.us.r-project.org")
}
```

```

}

library(tidyverse)
library(broom)
library(wooldridge)
library(car)          # para vif()

```

Nota: en el enunciado original se pedía instalar **car** “en la consola”. Aquí lo dejamos **compatible y automático**, instalándolo solo si falta.

Cargar los datos

Usaremos un nuevo set de datos sobre salarios, llamado **wage2**.

```
df <- as_tibble(wage2)
```

Revisa qué contiene el set de datos con:

```
glimpse(df)
```

```

Rows: 935
Columns: 17
$ wage      <int> 769, 808, 825, 650, 562, 1400, 600, 1081, 1154, 1000, 930, 921~
$ hours     <int> 40, 50, 40, 40, 40, 40, 40, 40, 45, 40, 43, 38, 45, 38, 40, 50~
$ IQ        <int> 93, 119, 108, 96, 74, 116, 91, 114, 111, 95, 132, 102, 125, 11~
$ KWW       <int> 35, 41, 46, 32, 27, 43, 24, 50, 37, 44, 44, 45, 40, 24, 47, 37~
$ educ      <int> 12, 18, 14, 12, 11, 16, 10, 18, 15, 12, 18, 14, 15, 16, 16, 10~
$ exper     <int> 11, 11, 11, 13, 14, 14, 13, 8, 13, 16, 8, 9, 4, 7, 9, 17, 6, 1~
$ tenure    <int> 2, 16, 9, 7, 5, 2, 0, 14, 1, 16, 13, 11, 3, 2, 9, 2, 9, 10, 7,~
$ age       <int> 31, 37, 33, 32, 34, 35, 30, 38, 36, 36, 38, 33, 30, 28, 34, 35~
$ married   <int> 1, 1, 1, 1, 1, 1, 0, 1, 1, 1, 1, 1, 0, 1, 1, 1, 1, 1, 1, 1,~
$ black     <int> 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,~
$ south     <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,~
$ urban     <int> 1, 1, 1, 1, 1, 1, 1, 1, 0, 1, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1,~
$ sibs      <int> 1, 1, 1, 4, 10, 1, 1, 2, 2, 1, 1, 1, 2, 3, 1, 1, 3, 2, 3, 3, 0~
$ brthord   <int> 2, NA, 2, 3, 6, 2, 2, 3, 3, 1, 1, 2, NA, 1, 1, 2, 3, 3, 1, 2, ~
$ meduc     <int> 8, 14, 14, 12, 6, 8, 8, 8, 14, 12, 13, 16, 12, 10, 12, 6, 12, ~
$ feduc     <int> 8, 14, 14, 12, 11, NA, 8, NA, 5, 11, 14, NA, 12, 10, 12, 8, 10~
$ lwage     <dbl> 6.645091, 6.694562, 6.715384, 6.476973, 6.331502, 7.244227, 6.~

```

Propiedades de las variables omitidas (Omitted Variable Bias)

Considera el siguiente modelo de regresión:

$$\log(wage) = \beta_0 + \beta_1 educ + \beta_2 IQ + u$$

donde **wage** es la **tasa salarial por hora** (en centavos, no en dólares).

Queremos verificar la propiedad mostrada en Wooldridge:

$$\tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_2 \tilde{\delta}_1$$

donde:

- $\tilde{\beta}_1$ proviene de la regresión de $\log(wage)$ sobre **educ** (modelo “corto”).
- $\tilde{\delta}_1$ proviene de la regresión de **IQ** sobre **educ**.
- $\hat{\beta}_1$ y $\hat{\beta}_2$ provienen del modelo “completo” (con **educ** e **IQ**).

1) Regresión de IQ sobre educ (para obtener $\tilde{\delta}_1$)

```
est1 <- lm(IQ ~ educ, data = df)
summary(est1)
```

Call:

```
lm(formula = IQ ~ educ, data = df)
```

Residuals:

Min	1Q	Median	3Q	Max
-50.228	-7.262	0.907	8.772	37.373

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	53.6872	2.6229	20.47	<2e-16 ***
educ	3.5338	0.1922	18.39	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.9 on 933 degrees of freedom

Multiple R-squared: 0.2659, Adjusted R-squared: 0.2652

F-statistic: 338 on 1 and 933 DF, p-value: < 2.2e-16

2) Regresión de $\log(wage)$ sobre educ (para obtener $\tilde{\beta}_1$)

Primero crea la variable $\log(wage)$ (si no recuerdas `mutate()`, revisa los labs anteriores):

```
df <- df %>% mutate(logwage = log(wage))
```

Ahora estima el modelo “corto”:

```
est2 <- lm(logwage ~ educ, data = df)
summary(est2)
```

Call:

```
lm(formula = logwage ~ educ, data = df)
```

Residuals:

Min	1Q	Median	3Q	Max
-1.94620	-0.24832	0.03507	0.27440	1.28106

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.973062	0.081374	73.40	<2e-16 ***
educ	0.059839	0.005963	10.04	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4003 on 933 degrees of freedom

Multiple R-squared: 0.09742, Adjusted R-squared: 0.09645

F-statistic: 100.7 on 1 and 933 DF, p-value: < 2.2e-16

3) Regresión completa de $\log(wage)$ sobre educ y IQ (para obtener $\hat{\beta}_1$ y $\hat{\beta}_2$)

```
est3 <- lm(logwage ~ educ + IQ, data = df)
summary(est3)
```

Call:

```
lm(formula = logwage ~ educ + IQ, data = df)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-2.01601	-0.24367	0.03359	0.27960	1.23783

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.6582876	0.0962408	58.793	< 2e-16 ***
educ	0.0391199	0.0068382	5.721	1.43e-08 ***
IQ	0.0058631	0.0009979	5.875	5.87e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3933 on 932 degrees of freedom

Multiple R-squared: 0.1297, Adjusted R-squared: 0.1278

F-statistic: 69.42 on 2 and 932 DF, p-value: < 2.2e-16

Verifica que se cumple la identidad:

```
# Extraer coeficientes
beta1_tilde <- coef(est2)["educ"]
beta1_hat <- coef(est3)["educ"]
beta2_hat <- coef(est3)["IQ"]
delta1_tilde <- coef(est1)["educ"]

# Verificar la identidad
cat(" (modelo corto):", beta1_tilde, "\n")
```

(modelo corto): 0.05983921

```
cat(" (modelo completo):", beta1_hat, "\n")
```

(modelo completo): 0.0391199

```
cat(" (modelo completo):", beta2_hat, "\n")
```

(modelo completo): 0.005863132

```
cat(" (IQ sobre educ):", delta1_tilde, "\n")
```

(IQ sobre educ): 3.533829

```
cat("\nVerificación: _tilde = _hat + _hat * _tilde\n")
```

Verificación: $\tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_1 \times \tilde{\beta}_1$

```
cat("Lado izquierdo:", beta1_tilde, "\n")
```

Lado izquierdo: 0.05983921

```
cat("Lado derecho:", beta1_hat + beta2_hat * delta1_tilde, "\n")
```

Lado derecho: 0.05983921

```
cat("¿Son iguales?",  
    abs(beta1_tilde - (beta1_hat + beta2_hat * delta1_tilde)) < 0.0001, "\n")
```

¿Son iguales? TRUE

Pregunta: ¿ $\tilde{\beta}_1$ es mayor o menor que $\hat{\beta}_1$? ¿Qué significa esto en términos de **sesgo por variable omitida**?

Multicolinealidad

Ahora veamos cómo calcular diagnósticos de multicolinealidad. Recuerda de Wooldridge que la multicolinealidad puede interpretarse mejor como “un problema de tamaño muestral pequeño”.

Usaremos el set de datos `meapsingle` del paquete `wooldridge`. Nos interesa la variable `pctsgle`, que entrega el porcentaje de familias monoparentales que residen en el mismo ZIP code que la escuela. La variable resultado es `math4`, que corresponde al porcentaje de estudiantes que aprobaron el test estatal de matemáticas de 4° grado.

1) Cargar el set de datos y estimar math4 sobre pctsgle

```
df <- as_tibble(meapsingle)

est_a <- lm(math4 ~ pctsgle, data = df)
summary(est_a)
```

Call:

```
lm(formula = math4 ~ pctsgle, data = df)
```

Residuals:

Min	1Q	Median	3Q	Max
-47.791	-8.310	1.600	8.092	50.317

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	96.77043	1.59680	60.60	<2e-16 ***
pctsgle	-0.83288	0.07068	-11.78	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.48 on 227 degrees of freedom

Multiple R-squared: 0.3795, Adjusted R-squared: 0.3768

F-statistic: 138.9 on 1 and 227 DF, p-value: < 2.2e-16

Pregunta: Interpreta el coeficiente de pendiente de esta regresión. ¿El efecto parece grande?

2) Correlación entre lmedinc y free

Ahora considera el mismo modelo, pero agregando lmedinc y free como regresores adicionales.

- lmedinc es el log del ingreso mediano del hogar del ZIP code.
- free es el porcentaje de estudiantes que califican para almuerzo gratis o con descuento.

¿Crees que podría haber una correlación fuerte entre lmedinc y free? Calcula la correlación:

```
correlacion <- cor(df$lmedinc, df$free)
cat("Correlación entre lmedinc y free:", round(correlacion, 4), "\n")
```

Correlación entre `lmedinc` y `free`: -0.747

Preguntas:

- ¿El signo de la correlación es el esperado?
- ¿Está lo suficientemente cerca de 1 en valor absoluto como para violar la suposición de “no colinealidad perfecta”?

3) Modelo con `pctsgle`, `lmedinc` y `free`

```
est_b <- lm(math4 ~ pctsgle + lmedinc + free, data = df)
summary(est_b)
```

Call:

```
lm(formula = math4 ~ pctsgle + lmedinc + free, data = df)
```

Residuals:

Min	1Q	Median	3Q	Max
-34.919	-7.195	0.931	7.313	50.152

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	51.72322	58.47814	0.884	0.377
<code>pctsgle</code>	-0.19965	0.15872	-1.258	0.210
<code>lmedinc</code>	3.56013	5.04170	0.706	0.481
<code>free</code>	-0.39642	0.07035	-5.635	5.2e-08 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 11.7 on 225 degrees of freedom

Multiple R-squared: 0.4598, Adjusted R-squared: 0.4526

F-statistic: 63.85 on 3 and 225 DF, p-value: < 2.2e-16

Pregunta: Comenta el valor del coeficiente de `pctsgle` comparado con la primera regresión. ¿Qué puedes decir de `lmedinc` y `free` como variables de confusión (confounders)?

4) Cálculo de VIF (Variance Inflation Factors)

Un diagnóstico común para multicolinealidad es el **VIF**. Podemos usar la función `vif()` del paquete `car` para esto. Calcula los VIF del modelo anterior:

```
vif_values <- vif(est_b)
print(vif_values)
```

```
pctsgle lmedinc free
5.740981 4.118812 3.188079
```

VIFs de 10 o más suelen considerarse problemáticos, porque:

$$VIF = \frac{1}{1 - R_j^2}$$

lo que implica $R_j^2 > 0.9$. Ver p. 86 de Wooldridge.

5) ¿Es la multicolinealidad un problema?

La multicolinealidad suele ser un problema principalmente en sets de datos con **muestra pequeña**. A medida que el tamaño muestral aumenta, R_j^2 podría disminuir. Además, la variación total en x_j (i.e., SST_j) aumenta con el tamaño muestral. Por esto,