

Capítulo 2 Correlación y Regresión Simple

Econometría para la Gestión (ECO_EPG) - FEN UAH

Tabla de contenidos

1. 1. Material descargable

Descargar PDF de contenidos teóricos

El PDF “**Capítulo_2_Correlacion_regresion_simple**” desarrolla los siguientes temas principales (a modo de índice):

- Covarianza y correlación.
- Diagramas de dispersión.
- Prueba de hipótesis para la correlación.
- Ecuaciones lineales y modelo lineal simple.
- Método de mínimos cuadrados.
- Residuos y error estándar de la estimación.
- Predicción e intervalos de confianza.
- Coeficiente de determinación simple (R^2).
- Prueba de hipótesis sobre el parámetro de pendiente (β_1).

En este laboratorio llevaremos varios de estos conceptos a la práctica con **R**.

2. Configuración inicial en R

En esta sección cargaremos las **librerías** necesarias y definiremos la **ruta a los datos**.

2.1. Carga de librerías

```
# Cargamos las librerías necesarias para el laboratorio  
library(openxlsx) # leer archivos Excel (.xlsx)
```

💡 Tip

Si alguna librería no está instalada, puedes hacerlo con:

```
install.packages("openxlsx")
```

2.2. Definir la ruta de trabajo

Vamos a guardar la ruta donde están los datos en un objeto llamado **ruta_datos**. Así solo modificamos una línea si cambiamos la carpeta en el futuro.

```
# Definimos la ruta donde están los archivos de datos del laboratorio.  
# IMPORTANTE: Ajusta esta ruta si tu carpeta tiene otro nombre o ubicación.  
  
ruta_datos <- "C:/Users/manue/Desktop/lab-econometria/labs_epg/data_epg"  
  
# Podemos verificar el contenido de la carpeta (opcional)  
list.files(ruta_datos)
```

```
[1] "annos_mantenimiento.xlsx" "auto_peso_consumo.xlsx"  
[3] "costos.xlsx" "data_PCA_Decathlon.csv"  
[5] "data_PCA_ExpertWine.csv" "Ejemplo1.xlsx"  
[7] "Ejemplo2.xlsx" "millaje.txt"  
[9] "orange.csv" "tabla_ejemplo_R.xlsx"
```

ℹ️ Nota

En R es recomendable usar / (slash) en lugar de *** en las rutas de Windows. Por eso escribimos "C:/Users/manue/Desktop/..." en lugar de "C:Users...".

3. Ejemplo 1: Correlación entre peso del auto y consumo de gasolina

En este ejemplo estudiaremos la relación entre:

- Peso_Libras: peso del automóvil (en libras).
- Consumo_Millas_por_galon: rendimiento (millas por galón).

La idea es:

1. Graficar un **diagrama de dispersión**.
2. Calcular el **coeficiente de correlación**.
3. Realizar una **prueba de hipótesis** para ver si la correlación es distinta de cero.

3.1. Lectura de los datos de autos

```
archivo_autos <- file.path(ruta_datos, "auto_peso_consumo.xlsx")

datos <- read.xlsx(
  archivo_autos,
  sheet    = "Hoja1",
  colNames = TRUE
)

# Vemos las primeras filas
head(datos)
```

	Auto	Peso_Libras	Consumo_Millas_por_galon
1	1	2743	21.4
2	2	3518	15.2
3	3	1855	38.9
4	4	5214	12.7
5	5	4341	17.8


Esperamos que el archivo contenga, al menos, las columnas:

- Peso_Libras
- Consumo_Millas_por_galon

3.2. Diagrama de dispersión

El **diagrama de dispersión** nos permite ver visualmente si existe una relación lineal entre las variables.

```
plot(  
  datos$Peso_Libras,  
  datos$Consumo_Millas_por_galon,  
  xlab = "Peso (libras)",  
  ylab = "Consumo (millas por galón)",  
  main = "Relación entre peso del auto y consumo"  
)
```



i Nota

- Si al aumentar el peso el consumo (millas por galón) **disminuye**, la nube de puntos tendrá una forma descendente → **correlación negativa**.
- Si al aumentar el peso el consumo **aumentara**, veríamos una nube ascendente → **correlación positiva**.
- Si no hay patrón claro, la correlación podría ser cercana a cero.

3.3. Cálculo de la correlación

El coeficiente de correlación de Pearson mide la **intensidad y dirección** de la relación lineal entre dos variables numéricas.

```
r <- cor(datos$Peso_Libras, datos$Consumo_Millas_por_galon)  
r
```

```
[1] -0.8549912
```

- r está entre -1 y 1.
- ($r < 0$): relación negativa.
- ($r > 0$): relación positiva.
- ($|r|$) cercano a 1 \rightarrow relación lineal fuerte.
- ($|r|$) cercano a 0 \rightarrow relación lineal débil.

3.4. Prueba de hipótesis para la correlación (cálculo manual)

En la teoría se plantea la prueba:

$$H_0 : \rho = 0 \quad \text{vs} \quad H_1 : \rho \neq 0$$

La idea es ver si la correlación poblacional (ρ) podría ser cero o no.

En el script se calcula el **error estándar** del coeficiente de correlación y luego el estadístico t:

```
# Cálculo manual basado en la fórmula del error estándar de r  
sr <- sqrt((1 - r) / 3) # comentario original: n número de datos menos 2  
  
t <- r / sr # estadístico t aproximado  
  
t
```

```
[1] -1.087305
```

Luego se calcula el **valor crítico** y el **p-valor** usando la distribución t de Student:

```
c <- qt(0.025, 3, lower.tail = FALSE) # valor crítico (cola superior)  
c
```

```
[1] 3.182446
```

```
# p-valor aproximado  
pt(-t, 3, lower.tail = FALSE)
```

```
[1] 0.1782267
```

i Nota

- Si el **p-valor** es pequeño (por ejemplo, menor que 0.05), rechazamos (H_0) y concluimos que la correlación es **significativamente distinta de cero**.
- Si el p-valor es grande, no tenemos evidencia suficiente para afirmar que exista correlación lineal distinta de cero.

3.5. Prueba de hipótesis para la correlación con cor.test

En lugar de hacer todos los cálculos “a mano”, R nos ofrece la función `cor.test`, que:

- Calcula el coeficiente de correlación.
- Realiza la prueba de hipótesis.
- Entrega el p-valor y un intervalo de confianza para ().

```
cor.test(datos$Peso_Libras, datos$Consumo_Millas_por_galon)
```

```
Pearson's product-moment correlation
```

```
data: datos$Peso_Libras and datos$Consumo_Millas_por_galon  
t = -2.8553, df = 3, p-value = 0.06483  
alternative hypothesis: true correlation is not equal to 0  
95 percent confidence interval:  
-0.9902684 0.1110238
```

```
sample estimates:  
cor  
-0.8549912
```

💡 Tip

Siempre que sea posible, conviene **verificar los resultados manuales** con funciones integradas como `cor.test`, ya que éstas manejan bien detalles como el tamaño de muestra, grados de libertad y supuestos.

4. Ejemplo 2: Correlación y regresión del costo de mantenimiento

En este ejemplo utilizamos datos de:

- `Tiempo_operacion`: años de operación de un bus.
- `Costo_Mantenimiento`: costo anual de mantenimiento (por ejemplo, en dólares).

Queremos:

1. Ver si existe correlación entre el tiempo de operación y el costo de mantenimiento.
2. Ajustar una **regresión lineal simple** para predecir el costo a partir del tiempo.
3. Evaluar los residuos y la calidad del ajuste.
4. Calcular predicciones e intervalos de confianza.

4.1. Lectura de los datos de mantenimiento

```
archivo_mant <- file.path(ruta_datos, "annos_mantenimiento.xlsx")  
  
datos2 <- read.xlsx(  
  archivo_mant,  
  sheet    = "Hoja1",  
  colNames = TRUE  
)  
  
head(datos2)
```

Bus	Costo_Mantenimiento	Tiempo_operacion
1	859	8
2	682	5
3	471	3
4	708	9
5	1094	11
6	224	2


Esperamos las columnas:

- Tiempo_operacion
- Costo_Mantenimiento

4.2. Diagrama de dispersión

```
plot(
  datos2$Tiempo_operacion,
  datos2$Costo_Mantenimiento,
  xlab = "Tiempo de operación (años)",
  ylab = "Costo de mantenimiento (unidades monetarias)",
  main = "Relación entre tiempo de operación y costo de mantenimiento"
)
```

Relación entre tiempo de operación y costo de mantenimiento:



i Nota

Este gráfico permite ver si al aumentar los años de operación los costos de mantenimiento tienden a subir.
Si la nube de puntos sugiere una recta ascendente, tiene sentido ajustar un modelo lineal.

4.3. Cálculo de la correlación y prueba de hipótesis

```
r <- cor(datos2$Tiempo_operacion, datos2$Costo_Mantenimiento)  
r
```

```
[1] 0.9376733
```

Nuevamente, calculamos el error estándar y el estadístico t de forma manual (siguiendo la lógica del script original):

```
sr <- sqrt((1 - r) / 7) # comentario original: aquí se usa 7 como "n - 2"  
t <- r / sr  
t
```