

Análisis Factorial

Fernando A. Crespo R.

November 16, 2023



6.1 Objetivo Análisis de Componentes Principales

- ▶ Principal Component Analysis (PCA) es un método estadístico que permite simplificar la complejidad de espacios muestrales con muchas dimensiones a la vez que conserva su información.
- ▶ Suponga que existe una muestra con n individuos cada uno con p variables (X_1, X_2, \dots, X_p) , es decir, el espacio muestral tiene p dimensiones. PCA permite encontrar un número de factores subyacentes ($z < p$) que explican aproximadamente lo mismo que las p variables originales. Donde antes se necesitaban p valores para caracterizar a cada individuo, ahora bastan z valores. Cada una de estas z nuevas variables recibe el nombre de componente principal.

6.1 Objetivo Análisis de Componentes Principales

- ▶ Es un método que sirve para reducir dimensiones, perteneciente a los métodos de *unsupervised learning*, porque importa extraer la información importante de las variables predictoras, no la variable a predecir.
- ▶ Es útil de usar, antes que otras técnicas de análisis de datos.

6.3 Interpretación Intuitiva de Componentes Principales

- Supongamos unos datos espaciales.




Figure: 6.1.

6.3 Interpretación Intuitiva de Componentes Principales

- Para reducir variables hay que buscar la dirección de máxima información (o varianza).




Figure: 6.2.

6.3 Interpretación Intuitiva de Componentes Principales

- Después se ven las cargas sobre esos ejes preferentes.




Figure: 6.3.

6.3 Interpretación Intuitiva de Componentes Principales

- Después se busca la siguiente dirección preferente.




Figure: 6.4.

6.3 Interpretación Intuitiva de Componentes Principales

- Lo que queremos es que la proyección sobre el nuevo eje sea máximo:




Figure: 6.5.

6.3 Interpretación Intuitiva de Componentes Principales

- ▶ La mirada de los datos pueden ser vistos por individuos o por variables.
- ▶ Cuando se reducen variables el objetivo es observar los individuos con menos variables.

6.4 Primer Paso

- Normalizar los datos por cada variable, si las unidades de medida son diferentes.

$$y_{ik} = \frac{x_{ik} - \bar{x}}{s_k} \quad (1)$$

6.5 Matriz de correlación

- ▶ Antes de despejar la factorización de la matriz, obtenemos los test de Barlett, para ver si las desviaciones estándar son homogéneas, es decir si esférico, y el test KMO para ver si el muestro de la variable es relevante o no para el modelo. A mayor valor, mejor, más relevante la variable para el modelo.
- ▶ Estando las variables normalizadas, usamos la matriz de correlación:

$$R = Y^t Y \quad (2)$$

Con el número de dimensiones igual al número de variables.

- ▶ Y a esa matriz le sacamos los valores propios:

$$Ru = \lambda u \quad (3)$$

Cada uno de esos vectores corresponde a los ejes preferenciales de información.

6.5 Matriz de correlación

- Cada λ_i corresponde a una parte de la varianza, y su porcentaje de contribución es:

$$\text{contribución}_i = \lambda_i / \sum_i \lambda_i \quad (4)$$